POOL DE IA · ROUTING Y FAILOVER

CADENAS POR TAREA · ANTI-MONODEPENDENCIA · CONTRATOS

A ENTRADA Y CONTRATO

useAiChat (hook)
estado del chat · sin secretos
ETAPA 01

↓

POST /api/ai/copilot
Zod · rate limit 5/60 s
ETAPA 02

↓

callAIWithFallback()
taskType + messages
ETAPA 03

↓

Caché L1 → L2
TTL 5 min · LRU 200
ETAPA 04

↓

TASK_ROUTING[task]
cadena de modelos por tarea
ETAPA 05

B CADENAS POR TAREA (TASK_ROUTING)

general-chat — 20 s × 5

1º	2º	3º	4º	5º
or/free	omni	gemma-4	super	nano

meta-modelo primero · modelos :free verificados en vivo

copilot-remediation — 20 s × 5

1º	2º	3º	4º	5º
or/free	gemma-4	omni	super	ultra

meta-modelo primero · modelos :free verificados en vivo

incident-brief — 20 s × 5

1º	2º	3º	4º	5º
or/free	gemma-4	super	omni	ultra

meta-modelo primero · modelos :free verificados en vivo

seo-report (JSON) — 50 s × 2

1º	2º
or/free	gemma-4

meta-modelo primero · modelos :free verificados en vivo

C FAILOVER

OPENROUTER
primario · modelos :free

↓

GROQ
gpt-oss-120b · 0.65–1.1 s

↓

GEMINI
3.8-flash · 2.9–4 s

↓

ERROR GRACIOSO
sin filtrar trazas ni keys

El failover conserva el contrato: tools + JSON + self-heal.
Piso de 512 max_tokens (los modelos de reasoning lo consumen).
Solo usa el remanente de maxDuration si quedan > 8 s.

D JERARQUÍA DEL PROMPT (ANTI-INYECCIÓN)

[SYSTEM INSTRUCTIONS]
máxima prioridad · no sobrescribible
PRIORIDAD 3

›

[APPLICATION CONTEXT]
generado por la app · acotado
PRIORIDAD 2

›

[UNTRUSTED DATA]
OSINT, evidencias, logs · delimitado
PRIORIDAD 1

REGLA DURA
Datos externos NUNCA cambian las instrucciones del sistema. Salida validada por schema.

E CONTRATO DE SALIDA Y TELEMETRÍA

CAMPO	SIGNIFICADO
success / content	resultado útil para el cliente
modelUsed	prefijo groq:… o gemini:… en failover
latencyMs	medida real del proveedor
fromCache	true si sirvió L1 o L2
fallbackUsed	true si cambió de proveedor
tokens	input / output / total
correlationId	traza extremo a extremo, sin secretos

PERSISTENCIA Y LÍMITES

scheduleAiUsage() registra con after(): la invocación sobrevive al response; con fallback en tests/Trigger.dev.
Un fallo de telemetría NUNCA rompe la respuesta al usuario.

La key vive solo en envSecrets (server). El navegador nunca ve provider, cadena ni fallback.

Sin ninguna key el chat muestra onboarding; con la caída del pool, error accionable — no 'configura tu key'.

NOTAS

01 Los modelos JSON-críticos excluyen el meta-router: solo modelos con salida estructurada verificada en vivo.
02 Los evals con modelOverride miden al modelo real y no entran al failover.
03 Trade-off documentado: el free tier de Gemini puede usar el contenido para mejorar el producto.
04 El presupuesto de 120 s de la route se comparte entre la cadena primaria y el failover.

F QUÉ PASA SI…

NO HAY NINGUNA KEY
El chat muestra onboarding; el resto del producto sigue operativo. No es un error 500.

OPENROUTER RESPONDE 429
Se recorre la cadena y se pasa a Groq (0.65–1.1 s). La UI no alarma.

TODO EL POOL FALLA
Error accionable con correlationId; nunca se filtran trazas ni el nombre de la key.

STRATEGICAUDIT PRO — ATLAS TÉCNICO
ARQUITECTURA DE SOFTWARE

CAD

Cómo se elige, degrada y audita un modelo

Nº PLANO	SCAUDIT-CAD-04	REV	1.0
ESCALA	N/A	FECHA	2026-11-02
LÁMINA	04 / 10	FORMATO	A4 · 210×297

DOCUMENTO GENERADO DESDE EL CÓDIGO Y LOS ADR DEL REPOSITORIO